



**IMPLEMENTASI METODE CONVOLUTIONAL NEURAL NETWORK DENGAN  
ARSITEKTUR MOBILENETV2 UNTUK DETEKSI PENYAKIT DAUN TANAMAN  
JAGUNG**

( Studi Kasus : PT Jafran Indonesia )

**PROPOSAL SKRIPSI**

Diajukan guna memenuhi salah satu syarat untuk  
melakukan seminar proposal

Oleh :

**FIKI AVIANTONO**

**192410102002**

**PROGRAM STUDI TEKNOLOGI INFORMASI**

**FAKULTAS ILMU KOMPUTER**

**UNIVERSITAS JEMBER**

**2022**

## **A. JUDUL**

**“IMPLEMENTASI METODE CONVOLUTIONAL NEURAL NETWORK DENGAN ARSITEKTUR MOBILENETV2 UNTUK DETEKSI PENYAKIT DAUN TANAMAN JAGUNG (Studi kasus : PT. Jafran Indonesia )”**

## **B. LATAR BELAKANG**

Jagung atau *Zea Mays* adalah komoditas tanaman palawija utama di Indonesia. Jumlah kebutuhan masyarakat dan industri terhadap jagung cukup besar, seiring meningkatnya jumlah penduduk di Indonesia. Berdasarkan data dari survey yang telah dilakukan oleh Badan Pusat Statistik Indonesia 2020, produktivitas jagung di Indonesia sebesar 54,74 ku/ha. Pulau Jawa memiliki rata-rata produktivitas jagung lebih tinggi dibandingkan dengan luar Pulau Jawa (Buana Pura et al., 2021). Kesempatan ini dimanfaatkan oleh berbagai badan usaha untuk mendapatkan keuntungan dalam industri agribisnis. PT Jafran Indonesia adalah badan usaha yang bergerak di industri tersebut. Proses bisnis yang dilakukan diantaranya menjual produk varietas benih unggulan dan menjual produk benih yang disesuaikan dengan kebutuhan pelanggan. PT Jafran Indonesia berada di daerah kabupaten Jember, Jawa Timur. Dengan luas pabrik pengolahan kurang lebih 4.500 m<sup>2</sup>. PT Jafran Indonesia memiliki lahan produksi benih. Lahan untuk produksi benih jagung dapat berupa kepemilikan perusahaan ataupun bermitra dengan petani. Letak lahan dengan kepemilikan perusahaan berada diberbagai daerah, diantaranya Kabupaten Bondowoso dan Kababupaten Jember. Lahan-lahan tersebut bertujuan untuk memenuhi kebutuhan proses bisnis dan menjaga sistem menejemen mutu dari pada perusahaan.

Menurut (Buana Pura et al., 2021), Rata-rata produktivitas jagung indonesia yang terserang organisme pengganggu tanaman (OPT) mencapai 54,98 ku/ha. Hal tersebut berpengaruh besar terhadap produksi jagung di Indonesia. Peneliti melakukan wawancara dengan hasil ditemukannya permasalahan serangan oragnisme penggaggu pada tanaman jagung dialami PT Jafran Indonesia. Salah satu serangan organisme pengganggu tanaman (OPT) yang dialami yaitu serangan virus penyakit daun pada tanaman jagung. Penyakit daun pada tanaman jagung tersebut dapat mempengaruhi kualitas tanaman jagung. Adapun penyakit daun pada tanaman jagung diantaranya, hawar daun, bintik abu-abu, dan karat daun. Pencegahan awal penyakit pada daun pada tanaman jagung sangat sukar sekali diindetifikasi, karena penyakit daun pada tanaman jagung memiliki perbedaan yang tidak terlalu signifikan atau memliki kemiripan yang hampir sama satu sama lain. Ciri-ciri penyakit daun tanaman jagung membuat persepsi orang berbeda-beda ketika melakukan identifikasi secara langsung. Oleh

sebab itu, diharapkan adanya sistem untuk mendeteksi klasifikasi penyakit daun pada tanaman jagung untuk membantu keakuratan deteksi klasifikasi penyakit daun pada tanaman jagung.

*Computer vision* adalah seni atau ilmu dalam bidang teknologi untuk membuat mesin memahami tingkat tinggi dari pola dan representasi gambar atau video sehingga dapat membuat keputusan cerdas yang mirip dengan apa yang akan dilakukan manusia (Sarkar et al., 2018). Sistem berbasis *computer vision* telah diterapkan di area luas industri dan pertanian, contoh penerapan *computer vision* seperti, dalam penyortiran apel (Moallem et al., 2017; Unay et al., 2011), stroberi (Liming dan Yanchao, 2010), tomat (Arakeri, 2016; Clement et al., 2012), kentang (Moallem et al., 2013), kurma (Al Ohali, 2011; Lee et al., 2008), jeruk (Blasco et al., 2007; López-García et al., 2010), mangga (Naik dan Patel, 2014; Naik dkk., 2015; Nandi et al., 2014), mentimun (Clement et al., 2013) dll (Irer et al., 2019). Di bidang lainnya, *Computer vision* digunakan pada industri kesehatan untuk mendeteksi penyakit kanker mata (Santos-Bustos et al., 2022). *Computer vision* dapat dilakukan dengan menggunakan *deeplearning*. *Convolutional neural network* (CNN) yaitu pendekatan teknologi berbasis *deep learning*. *Convolutional neural network* (CNN) berisi layer-layer untuk mengekstrak fitur dan klasifikasi. CNN digunakan untuk memproses citra untuk mengenali suatu objek (Khan et al., 2018). Dari berbagai contoh penelitian diatas, terlihat bahwa *computer vision* dengan metode *convolutional neural network* (CNN) dapat mengatasi permasalahan berbagai bidang terkait klasifikasi.

Penelitian dengan judul “*Maize Leaf Disease Detection and Classification Using Machine Learning Algorithms*” bertujuan untuk melakukan percobaan teknik *machine learning* seperti *Naïve Bayes*, *Decision Tree*, *K-Nearest Neighbor*, *Support Vector machine* dan *Random Forest*, bertujuan untuk melakukan deteksi penyakit daun pada tanaman jagung menggunakan citra gambar. Algoritma *Random Forest* menghasilkan akurasi tertinggi 79.23% (Panigrahi et al., 2020). Penelitian yang lain dengan judul “*Identification and recognition of rice diseases and pests using convolutional neural networks*” mengidentifikasi penyakit dan hama pada tanaman padi dengan akurat dan efisiensi memori, menggunakan metode *deep learning* dengan teknik CNN. Salah satu model CNN yang digunakan pada penelitian tersebut yaitu *MobileNetV2* dengan menghasilkan akurasi 96.12% (Rahman et al., 2020). Penelitian yang lain dengan judul “*Depthwise separable convolution architectures for plant disease classification*” mengembangkan dan membandingkan berbagai model arsitektur CNN untuk klasifikasi penyakit tanaman berdasarkan gambar daun. Training dan testing dari model menggunakan dataset *PlantVillage* yang berisi 82.161 gambar dengan 55 kelas penyakit tanaman. Akurasi *Depthwise Separable Convolution* menyerupai akurasi model konvensional,

namun dengan jumlah parameter jauh lebih rendah. Model CNN *MobileNet* mendapatkan akurasi sebesar 98.65% dengan jumlah parameter 6 kali lebih rendah dari pada VGG16 (KC et al., 2019).

Dari beberapa masalah dan penjelasan terkait apa yang menjadi latar belakang penelitian ini. Penulis akan membuat sistem untuk mendeteksi penyakit daun tanaman jagung seperti, hawar daun, bintik abu-abu, dan karat daun. Penulis menggunakan *deeplearning* dengan metode *convolutional neural network* untuk mendeteksi klasifikasi penyakit daun pada tanaman jagung, karena akurasi yang bagus dalam mendeteksi suatu objek klasifikasi. Penulis menggunakan arsitektur *MobileNetV2* pada model CNN, bertujuan mendapatkan akurasi yang tinggi serta efisiensi ukuran model untuk deteksi penyakit daun pada tanaman jagung. Sehingga dapat diterapkan pada perangkat *mobile* karena ukuran model yang kecil dan latensi rendah. Sistem yang dibuat pada penelitian ini, diharapkan menghasilkan performa yang bagus dan dapat menjadi solusi bagi tempat studi kasus penelitian ini.

### C. RUMUSAN MASALAH

Berdasarkan uraian latar belakang yang menjadi isi penelitian ini, penulis melakukan perumusan masalah sebagai berikut:

- a. Bagaimana sistem deteksi penyakit daun pada tanaman jagung metode *convolutional neural network* dengan arsitektur *MobileNetV2* ?
- b. Bagaimana performa *convolutional neural network* arsitektur *MobileNetV2* untuk melakukan deteksi penyakit daun tanaman jagung ?

### D. BATASAN MASALAH

Adapun batasan yang digunakan peneliti sebagai acuan dalam melakukan penelitian ini :

- a. Penelitian ini mengimplemetasikan metode CNN dengan arsitektur *MobileNetV2* berbasis web.
- b. Penyakit pada daun jagung yang diteliti adalah hawar daun (*bight*), bintik abu-abu (*grey leaf spot*), karat daun (*common rust*), dan daun sehat.
- c. Dataset yang digunakan pada penelitian ini yaitu dataset *PlantVillage* berasal dari web dengan url: <https://www.kaggle.com/smaranjitghose/corn-or-maize-leaf-disease-dataset> (Singh et al., 2020).

## **E. TUJUAN PENELITIAN**

- a. Membuat sistem deteksi penyakit daun pada tanaman jagung menggunakan metode Convolutional Neural Network dengan arsitektur *MobileNetV2*.
- b. Melakukan pengujian performa atas model CNN arsitektur *MobileNetV2* untuk deteksi penyakit daun pada tanaman jagung.

## **F. MANFAAT**

Adapun manfaat yang akan dicapai pada penelitian ini :

- a. Bagi Akademik.  
Penelitian ini diharapkan mampu memberikan informasi terkait judul penelitian pada Program Studi Teknologi Informasi Universitas Jember.
- b. Bagi Peneliti.  
Menerapkan ilmu pengetahuannya, untuk membangun sistem deteksi klasifikasi objek berdasarkan citra gambar.
- c. Bagi Perusahaan.  
Memberikan solusi atas masalah yang dimiliki perusahaan menggunakan sistem identifikasi penyakit daun pada tanaman jagung.

## **G. TINJAUAN PUSTAKA**

Tinjauan berisi teori-teori berkaitan dengan penelitian, teori pada penelitian ini diperoleh dari berbagai literatur seperti buku, jurnal, dan artikel.

### **G.1 Penelitian terdahulu**

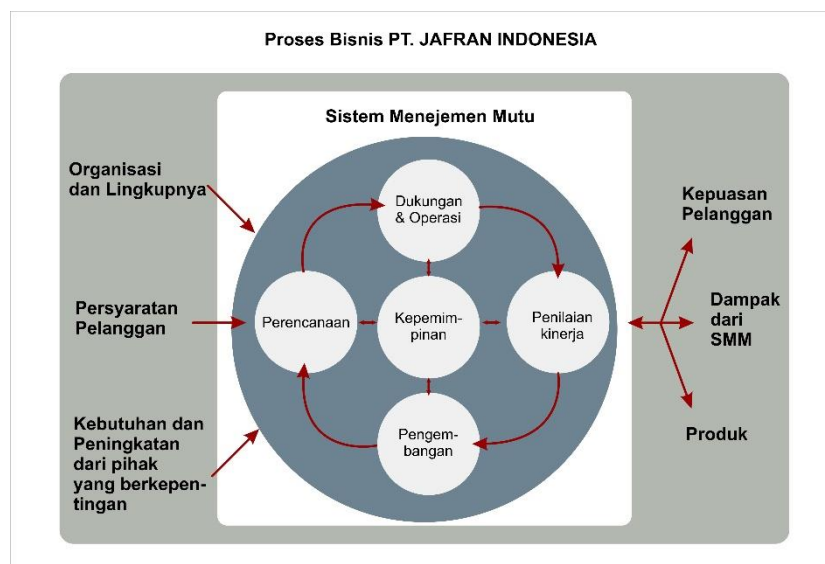
Penelitian dengan judul “*Maize Leaf Disease Detection and Classification Using Machine Learning Algorithms*” bertujuan untuk melakukan percobaan teknik machine learning seperti *Naïve Bayes*, *Decision Tree*, *K-Nearest Neighbor*, *Support Vector machine* dan *Random Forest*, bertujuan untuk melakukan deteksi penyakit daun pada tanaman jagung menggunakan citra gambar. Dihasilkan algoritma Random Forest dengan akurasi tertinggi 79.23% (Panigrahi et al., 2020).

Penelitian yang lain dengan judul “*Identification and recognition of rice diseases and pests using convolutional neural networks*” mengidentifikasi penyakit tanaman dan hama pada tanaman padi dengan akurat dan tepat untuk membantu petani dalam perawatan tanaman dan mengurangi tingkat kerugian ekonomi substansial. Menggunakan pembelajaran deep learning dengan metode CNN dalam klasifikasi gambar. Terdapat dua tahapan untuk membandingkan

model dengan skala ukuran kecil dan dapat digunakan untuk perangkat seluler. Model tahap pertama yaitu CNN dengan arsitektur VGG16 dan InceptionV3 yang telah ditraining untuk klasifikasi penyakit padi dan hama. Hasil percobaan tahap pertama menunjukkan keefektifan dalam mendeteksi data, namun arsitektur memiliki skala yang besar. Pada tahapan percobaan kedua merupakan arsitektur CNN yang diusulkan seperti *MobileNetV2*, *Nasnet Mobile*, dan *SqueezeNet*. Hasil percobaan menunjukkan arsitektur yang diusulkan mencapai akurasi yang sebesar 93.3% dan ukuran model yang lebih kecil 99% daripada model hasil percobaan pertama, misal VGG16 (Rahman et al., 2020).

Penelitian yang lain dengan judul “*Depthwise separable convolution architectures for plant disease classification*” mengembangkan dan membandingkan berbagai model arsitektur CNN untuk klasifikasi penyakit tanaman berdasarkan gambar daun. Training dan testing dari model menggunakan dataset *PlantVillage* yang berisi 82.161 gambar dengan 55 kelas penyakit tanaman. Akurasi *Depthwise separable convolution* CNN menyerupai akurasi model konvensional, namun dengan jumlah parameter yang jauh lebih rendah. *MobileNet* merupakan salah satu model yang menggunakan *Depthwise separable convolution* dalam arsitektur layernya. Model CNN *MobileNet* yang diuji mendapatkan akurasi sebesar 98.65% (KC et al., 2019).

## G.2 PT Jafran Indonesia



gambar 1. Proses bisnis PT Jafran Indonesia

Jafran Indonesia merupakan sebuah badan usaha perseroan terbatas yang bergerak di bidang agribisnis khususnya di jual benih jagung. Letak daripada PT Jafran Indonesia berada di Desa Rowotamtu, Kec. Rambipuji, Kab. Jember, Jawa timur. Memliki luas pabrik

pengolahan produksi benih sekitar 4.500 meter persegi. Proses bisnis yang dilakukan PT Jafran Indonesia yaitu menjual produk varietas benih jagung unggulan diantaranya, AR 998, AR 21, JF 18, dan AR 29. Selain hal tersebut, PT. Jafran Indonesia juga membuat produk benih jagung unggulan yang disesuaikan dengan persyaratan pelanggan. Tujuannya agar dapat memenuhi kebutuhan dan peningkatan dari semua pihak yang berkepentingan, sehingga hasil produk dan kepuasan pelanggan dapat terjaga dengan baik. Sistem manajemen mutu dapat terealisasi untuk menjaga proses bisnis PT Jafran Indonesia berkembang dengan baik.

### **G.3 Penyakit daun tanaman jagung**

Penyakit tanaman jagung disebabkan oleh 3 komponen penyebab utama yang berinteraksi satu sama lain. Komponen penyebab penyakit tanaman jagung diantaranya, patogen (organisme kecil penyebab infeksi), inang (organisme yang menampung organisme lain), dan lingkungan. Epidemi (wabah) penyakit merupakan meningkatnya intensitas komponen penyebab penyakit. Hal tersebut terjadi, karena tingkat sumbangan yang besar diberikan oleh masing-masing komponen penyebab utama menyebabkan penurunan hasil tanaman jagung. Penyakit jagung *parasitic* merupakan penyakit yang disebabkan oleh organisme pengganggu tanaman seperti virus, jamur, tumbuhan parasite, dan sejenisnya. Sedangkan yang bukan patogenik (fisiologis) diakibatkan keadaan sekitar yang tidak menunjang untuk melakukan pertumbuhan. Penyakit daun tanaman jagung adalah penyakit yang diakibatkan oleh penyakit *parasitic*. Terdapat beberapa macam penyakit daun tanaman jagung diantaranya, hawar daun (*Leaf Blight*), bitnik abu-abu (*grey leaf spot*), dan karat daun (*Common rust*)(Sudjono, 2018).

#### **G.3.1 Hawar Daun (*Northern Leaf Blight*)**




**gambar 2.Hawar Daun (*Northern Leaf Blight*)**

Hawar daun atau *Northern leaf blight* diakibatkan oleh jamur *Exserohilum turcicum*. Suhu tinggi sampai sedang dan kelembapan tinggi mendukung perkembangan hawar daun (*Northern leaf blight*)(Sibiya & Sumbwanyambe, 2019). Gejala umum dikenali dari lesi berbentuk oval memanjang yang relatif besar dan dapat berkembang pada daun. Bercak

memanjang 2.5 hingga 15cm menjadi bercak kering nekrotik dan luas (hawar) dengan warna keabu-abuan. Indikasi terjangkitnya penyakit tinggi maka tanaman akan cepat mati seperti terbakar atau mengering(Sudjono, 2018).

### **G.3.2 Bintik daun abu-abu (*grey leaf spot*)**



gambar 3. Bintik abu-abu ( *Grey Leaf Spot* )

Bercak daun kelabu memiliki bentuk bercak seperti bintik pada daun jagung yang disebabkan oleh jamur *Cercospora zeae-maydis*. Biasanya hal tersebut terjadi pada saat tanaman belum berbunga, bercak dapat memanjang dan membesar seiring dengan suhu hangat lingkungan serta kelembapan yang tinggi. Sekarang dilihat sebagai salah satu penyakit jagung (jagung) yang membatasi hasil yang paling signifikan di seluruh dunia, menimbulkan masalah yang serius ancaman terhadap produksi jagung di banyak wilayah di Amerika Serikat bagian timur dan, baru-baru ini, di wilayah yang luas dari Sabuk Jagung AS dan Afrika. Biasanya, gejalanya diamati pada daun bagian bawah. Dengan bentuk bintik bintik keabu-abuan mengering(Sibiya & Sumbwanyambe, 2019).

### **G.3.3 Karat daun ( *Common rust* )**



gambar 4. Karat Daun ( *Common Rust* )

Penyakit karat daun disebabkan oleh *pathogen puccinia sorghi*. Suhu yang menyebabkan relatif dingin 16 -23 derajat Celsius dan tingkat kelembapan yang relatif tinggi.



Bercak-bercak kecil dengan warna oranye, coklat, dengan panjang 0,2 sampai 2 mm, terdapat pada permukaan daun atas dan bawah. Uredinia ini menghasilkan urediniospora (uredospora) bulat berwarna kuning sampai keemasan(Sudjono, 2018). Fungsional area daun dan fotosintesis berkurang oleh lesi penyakit karat daun. Bintik-bintik atau bercak kecil ditemukan pada permukaan daun atas dan bawah(Sibiya & Sumbwanyambe, 2019).

#### **G.4 Computer vision**

*Computer vision* adalah seni atau ilmu untuk membuat mesin memahami tingkat tinggi pola dan representasi dari gambar dan video sehingga dapat membuat keputusan cerdas yang mirip dengan apa yang akan dilakukan manusia(Sarkar et al., 2018). Penggunaan teknologi computer vision diharapkan dapat menganalisis pola suatu gambar atau video dengan akurasi yang sangat tinggi, seperti manusia menggunakan indera penglihatan untuk melihat dan memahami sekitarnya. *Computer vision* berusaha untuk mengembangkan metode yang mampu mereplikasi salah satu kemampuan yang paling menakjubkan dari sistem penglihatan manusia, yaitu bentuk karakter objek menggunakan cahaya yang dipantulkan ke mata, sehingga dapat menyimpulkan berbagai macam objek(Khan et al., 2018).

Sistem berbasis *computer vision* telah diterapkan di area luas industri berbasis makanan dan pertanian dalam penyortiran apel (Moallem et al., 2017; Unay et al., 2011), stroberi (Liming dan Yanchao, 2010), tomat (Arakeri, 2016; Clement et al., 2012), kentang (Moallem et al., 2013), kurma (Al Ohali, 2011; Lee et al., 2008), jeruk (Blasco et al., 2007; López-García et al., 2010), mangga (Naik dan Patel, 2014; Naik dkk., 2015; Nandi et al., 2014), mentimun (Clement et al., 2013) dll(Ireri et al., 2019). Membuktikan hasil dari akurasi deteksi objek *computer vision* dapat diandalkan dalam berbagai bidang.

#### **G.5 Deep Learning**

*Deep Learning* menggunakan pola jaringan saraf dalam mengenali potensi yang berpengaruh besar untuk dipelajari seperti fungsi, pola, dan representasi non-linier yang kompleks(Sarkar et al., 2018). Cara kerja yang menyerupai sistem saraf manusia yang saling terhubung antar neuron nya. Mengenali objek kombinasi data seperti fungsi, pola, dan representasi non-linier yang kompleks.


Terdapat 3 keunggulan utama deep learning. Kesederhanaan yaitu cara kerja jaringan dalam menawarkan blok arsitektur dasar, lapisan jaringan yang diulang beberapa kali untuk menghasilkan jaringan yang besar. Skalabilitas artinya model *deep learning* mudah diskalakan ke kumpulan data besar. Transfer domain artinya model yang dipelajari pada satu tugas berlaku

untuk tugas terkait lainnya(Khan et al., 2018). Penggunaan deeplearning diharapkan bisa mengatasi masalah yang membutuhkan keakuratan yang baik dengan memanfaatkan 3 keunggulan tersebut.

## G.6 Convolutional Neural Network ( CNN )

*Convolutional neural network* (CNN) adalah pendekatan teknologi berbasis *deeplearning*. Arsitektur tersebut terdiri dari layer-layer yang memproses dan mengekstraksi fitur. CNN digunakan untuk memproses citra gambar agar dapat digunakan untuk mengklasifikasikan objek gambar yang dimaksud. Beberapa contoh penerapan CNN untuk mengidentifikasi objek citra satelit, citra medis, mendeteksi anomaly, dan lain sebagainya(Khan et al., 2018). CNN terdiri dari lapisan konvolusional (*Convolutional Layers*), penyatuan lapisan (*pooling layers*), *ReLU*, dan *fully-connected layers*. Jika lapisan tersebut dibangun dan disusun, maka arsitektur CNN akan terbentuk(O'Shea & Nash, 2015).

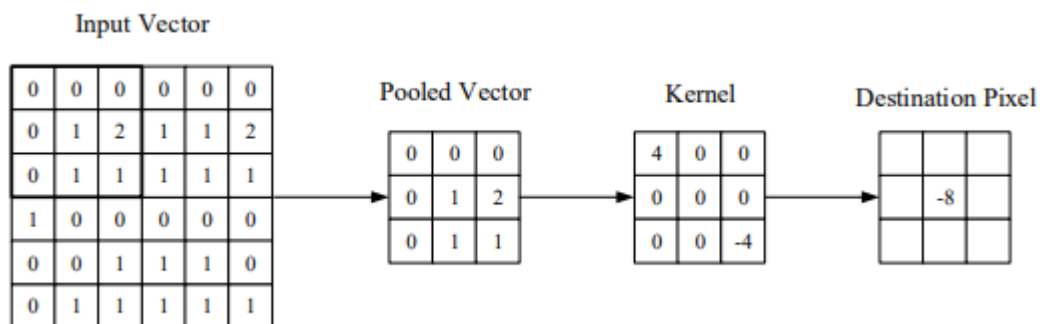
Dari gambar 5 merupakan gambaran dari arsitektur CNN, proses yang dilakukan pada setiap layers dengan penjelasan sebagai berikut :



gambar 5. Arsitektur CNN

### a. Convolutional Layer

*Convolutional Layer* merupakan proses utama yang menjadi dasar jaringan arsitektur CNN. Parameter jaringan (layers) berfokus pada bagian kernel yang dapat dipelajari. Filter berbentuk kecil dalam bentuk 2 dimensi, tetapi menyebar di sepanjang kedalaman kanal atau



gambar 6. Convolutional Layer

(channels) dari inputan. Ketika data mengenai convolutional layer, layer convolution menggabungkan tiap filter melintasi data spasial input menghasilkan *feature map* 2 dimensi (O'Shea & Nash, 2015).

Sebagai contoh, jika terdapat inputan dengan ukuran gambar  $64 \times 64 \times 3$  dan filter yang digunakan berukuran  $6 \times 6$ , maka akan mendapat total bobot 108 pada convolutional layer. Hal tersebut berasal dari ukuran channel atau kernel dari input sebesar 3 dikalikan dengan ukuran filter convolution yang berukuran  $6 \times 6$ , sehingga dihasilkan nilai bobot 108 ( $6 \times 6 \times 3$ ).

Convolutional layers mampu mengurangi kompleksitas model melalui optimasi outputnya. Optimasi dilakukan melalui tiga hyperparameter diantaranya, filter atau kernel untuk konvolusi, stride, dan zero-padding. Filter merupakan jumlah dari ukuran dimensi 2 dimensi yang digunakan pada saat convolution layer. Stride (langkah) merupakan nilai pergeseran filter pada saat melakukan *convolution layer*. Zero-padding adalah nilai untuk memberikan jarak tepi pada data input, sehingga nilai yang diberikan dapat menyesuaikan ukuran gambar input (O'Shea & Nash, 2015). Perhitungan tersebut, dapat dilihat pada rumus 1 berikut :

$$Output = \frac{N-F+2P}{S+1} \dots\dots\dots (1)$$

Keterangan :

N = Ukuran gambar ( $H \times W \times D$ )


F = Filter

S = besaran pergeseran filter yang digunakan (stride)

P = nilai untuk menyesuaikan ukuran gambar input (padding)

#### b. Pooling Layer

Lapisan pooling layer bertujuan untuk mengurangi dimensi dari ukuran input, sehingga dapat mengurangi jumlah parameter dan komputasi yang kompleks dalam model. Pooling layer merupakan filter yang memiliki ukuran dan langkah, sehingga dapat melakukan pergeseran seluruh area dimensi input. Proses operasi pooling layers dilakukan pada setiap dimensi input. Operasi pooling layers yang biasanya digunakan pada CNN yaitu Maxpooling dan Average-pooling. Maxpooling merupakan nilai maksimum feature map, sedangkan average-pooling merupakan nilai rata-rata nilai dari feature map.



gambar 7. *Pooling layer*

Pada contoh gambar 7, dijelaskan proses pooling layers menggunakan operasi max-pooling. Feature-map yang dihasilkan memiliki ukuran  $4 \times 4 \times 1$ . Filter yang digunakan untuk melakukan operasi pooling layer ukuran  $2 \times 2$  dengan nilai stride 2 langkah. Pada gambar 7 dijelaskan pola pergeseran proses pooling layer menggunakan warna. Dari feature map dilakukan operasi pooling layer menggunakan filter. Warna pada gambar 7 menjelaskan proses pooling layers, sehingga dimensi atau ukuran menyusut.

#### c. Rectified Linear Unit (ReLU)

Rectified Linier Unit merupakan aktivasi nonlinier untuk menjaga hasil proses konvolusi menjadi nilai positif. Sehingga angka yang dihasilkan bernilai negatif akan melalui proses ReLU, proses tersebut menjadikan nilai negative menjadi nol dan tidak berubah jika nilainya positif (Khan et al., 2018). Rumus ReLU dapat dilihat pada rumus 2 berikut:

$$f_{relu}(x) = \max(0, x) \dots \dots \dots (2)$$


#### d. Fully Connected Layer

*Fully Connected Layer* merupakan proses menghubungkan semua neuron dari layer sebelumnya dengan neuron di layer sesudahnya. Fitur yang dihasilkan pada layer konvolusi atau layer pooling masih data 2 dimensi, sehingga harus dilakukan flatten pada fitur agar dapat dilakukan proses fully connected layer. Keluaran dari proses fully connected layer umumnya berada pada layer klasifikasi.

### G.7 MobileNetV2

Mobilenet adalah arsitektur CNN yang disederhanakan menggunakan konvolusi menggunakan *depthwise separable convolutions* untuk membangun convolutional neural network yang ringan dan dapat menyediakan model yang efisien untuk aplikasi seluler dan perangkat citra tertanam. Model yang diimplementasikan pada sistem diharapkan bisa

digunakan secara cepat dengan latensi yang rendah, sehingga model dengan arsitektur ini layak digunakan pada perangkat mobile.



gambar 8. (a) Standard Convolution Filter, (b) Depthwise Convolutional Filters, (c) Pointwise Convolution Filters

*Depthwise Separable Convolutions* adalah metode untuk membangun blok layer membuat arsitektur model yang efisien. Dasar dari *Depthwise Separable Convolutions* yaitu membuat layer konvolusi menjadi dua bagian. Lapisan pertama disebut *depthwise convolution* bertujuan melakukan filter konvolusi tunggal setiap kanal input. lapisan kedua disebut *pointwise convolution* bertujuan melakukan konvolusi dengan menggunakan filter berukuran  $1 \times 1$  kepada seluruh kanal input. Hasil dari kedua bagian konvolusi tersebut akan menghasilkan fitur baru.

*Standard convolution* yaitu melakukan operasi konvolusi menggunakan filter pada seluruh kanal input. Hal tersebut mengakibatkan komputasi konvolusi standar menghasilkan komputasi yang besar, sedangkan pada *Depthwise Separable Convolutions* dilakukan dengan menggunakan 2 bagian konvolusi yang dijumlahkan menghasilkan biaya komputasi lebih rendah. Rumus daripada perhitungan komputasi operasi *Standar convolution* dan *Depthwise Separable Convolutions*, sebagai berikut :

Perhitungan biaya *Standard convolution* :

$$D_k \cdot D_k \cdot M \cdot D_l \cdot D_l \cdot N = D_k^2 \cdot M \cdot D_l^2 \cdot N \dots\dots\dots (3)$$

Perhitungan biaya *Depthwise Separable Convolutions* :

$$D_k \cdot D_k \cdot 1 \cdot D_l \cdot D_l \cdot M + 1 \cdot 1 \cdot M \cdot D_l \cdot D_l \cdot N \dots\dots\dots (4)$$

$$D_k D_k D_l D_l \cdot M + M \cdot D_l D_l N \dots\dots\dots (5)$$

$$D_k^2 \cdot D_l^2 \cdot M + M \cdot D_l^2 \cdot N \dots\dots\dots (6)$$

Keterangan :

$D_k$  = Ukuran dimensi filter

$M$  = Jumlah kanal dari input

$D_l$  = Ukuran dimensi fitur

$N$  = Jumlah kanal dari fitur

Perbandingan biaya konvolusi yang dilakukan dari *Standard convolution* dan *Depthwise Separable Convolutions* untuk melihat hasil reduksi yang dilakukan dari salah satu konvolusi tersebut. Persamaan dibawah merupakan perbandingan *Standard convolution* dan *Depthwise Separable Convolutions*.

$$\frac{D_k^2 \cdot D_l^2 \cdot M + M \cdot D_l^2 \cdot N}{D_k^2 \cdot M \cdot D_l^2 \cdot N} = \frac{1}{N} + \frac{1}{D_k^2} \dots\dots\dots (7)$$

Misal input filter yang digunakan menggunakan ukuran filter 3 x 3, maka hasil dari perbandingan tersebut menunjukan bahwa *Depthwise Separable Convolutions* menghasilkan perhitungan biaya komputasi 9 sampai 8 kali lebih kecil daripada standard konvolusi. Hal tersebut menjadikan konvolusi dengan bagian terpisah menghasilkan efisiensi komputasi yang lebih bagus daripada konvolusi standar(Sandler et al., 2018).

### G.8 Confusion Matrix

*Confusion Matrix* adalah cara yang digunakan untuk menghitung perfoma dari model klasifikasi yang dibuat. Terdapat empat acuan nilai parameter yang ada ditabel confusion matrix, di antaranya nilai *True Positive*, nilai *False Positive*, nilai *False Negative*, dan nilai *True Negative*.

Table 1. Tabel *Confusion Matrix*

		Nilai Nyata	
		Positif	Negatif
Nilai Prediksi	Positif	True Positif	False Positif
	Negatif	False Negatif	True Negatif

$$Accuracy = \frac{TP+TN}{TP+FP+TN+FN} \dots\dots\dots (8)$$

$$Precision = \frac{TP}{TP+FP} \dots\dots\dots (9)$$

$$Recall = \frac{TP}{TP+FN} \dots\dots\dots (10)$$

$$F - 1 \ score = \frac{2*Recall*Precision}{Recall+Precision} \dots\dots\dots (11)$$

### **G.9 Blackbox testing**

*Blackbox Testing* adalah pengujian perangkat berdasarkan pada fungsionalitas perangkat. Teknik ini digunakan untuk memastikan bahwa semua input yang dibutuhkan oleh sistem akan memberikan output yang benar. Manfaat melakukan blackbox testings diantaranya, melakukan pengujian yang rasional mengurangi kasus pengujian, sudut pandang pengguna menjadi dasar pengujian, dan efisiensi(Jan et al., 2016).

## **H. METODOLOGI PENELITIAN**

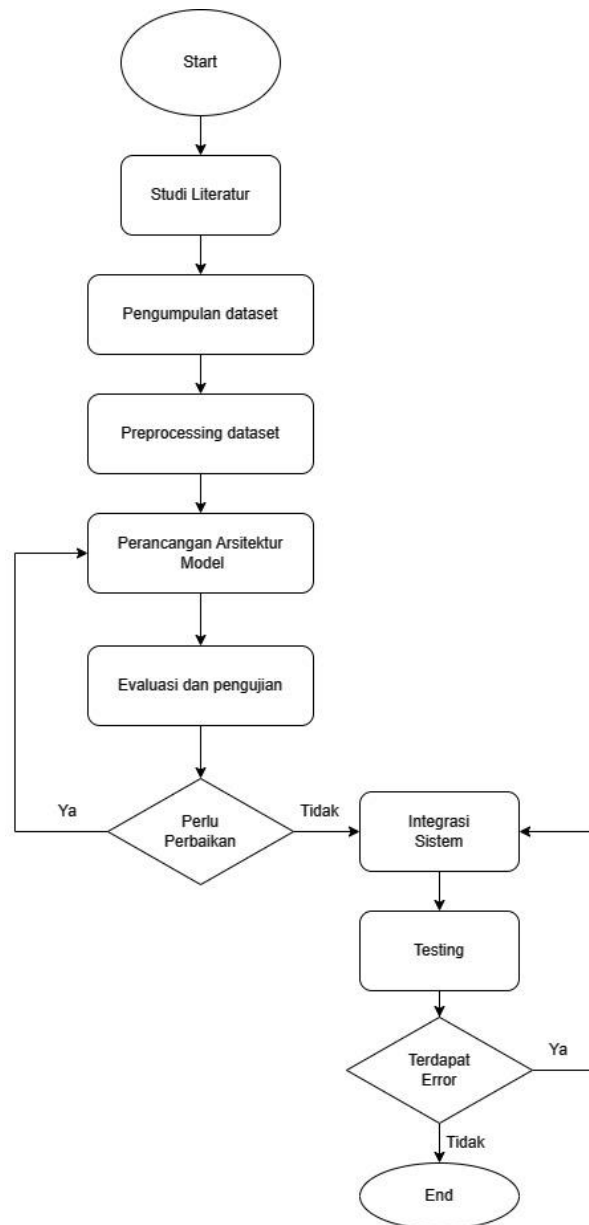
### **H.1 Jenis Penelitian**

Penelitian termasuk dalam penggunaan jenis penelitian terapan. Penelitian ini bertujuan untuk memberikan solusi atas permasalahan yang diteliti. Mengimplementasikan arsitektur MobileNetV2 untuk klasifikasi penyakit daun tanaman jagung.

### **H.2 Objek Penelitian**

Objek pada peneletian ini, yaitu penyakit daun tanaman jagung. Dataset yang digunakan total 2000 data. Penelitian ini bertempat di PT Jafran Indonesia dan Fakultas Ilmu Komputer Universitas Jember.

### H.3 Tahapan Pelaksanaan



gambar 9. Tahapan penelitian

#### H.3.1 Studi literatur

Proses di mana peneliti mencari studi literatur, mulai dari pencarian jurnal, data pendukung, dan materi yang dibutuhkan. Proses ini dilakukan untuk mendapatkan tinjauan pustaka untuk mendukung penelitian.

#### H.3.2 Pengumpulan dataset

Proses dengan tujuan untuk mengumpulkan dataset yang akan digunakan. Jumlah data yang diperlukan dari setiap jenis klasifikasi sama rata. Peneliti akan membagi rata jumlah data tiap kelas yaitu 500 data gambar. Tujuannya agar keakuratan terbagi sama rata ke setiap kelas



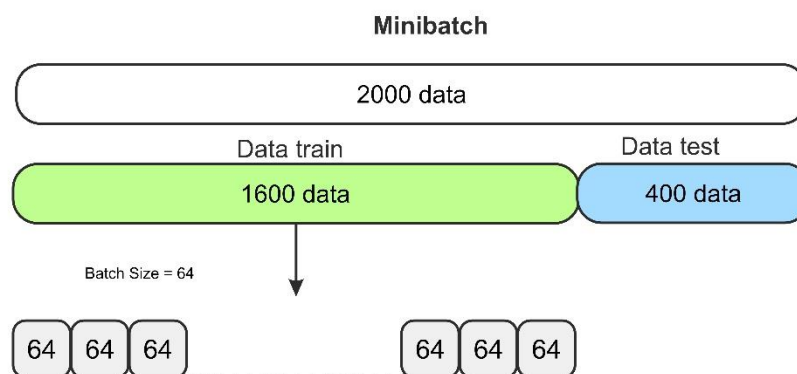
yang diuji. Dataset yang digunakan berasal dari data PlantVillage Dataset(Singh et al., 2020). Dataset tersebut berisi penyakit daun pada tanaman jagung yang dibutuhkan. Adapun kelas dan jumlah data yang digunakan, sebagai berikut :

- 1) Hawar daun : 500 data
- 2) Bintik abu-abu : 500 data
- 3) Karat daun : 500 data
- 4) Daun Sehat : 500 data

### H.3.3 Preprocessing dataset

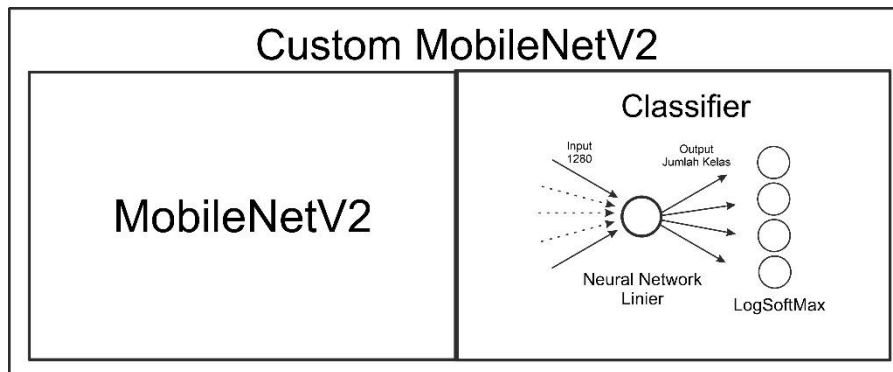
Preprocessing dataset merupakan proses melakukan pengolahan data. Tujuannya untuk mendapatkan variasi data yang digunakan sehingga variasi tersebut berguna melatih model mendapatkan akurasi yang lebih baik. Peneliti membagi datataset dengan perbandingan 80:20 dan 70:30 data untuk latih dan uji. Model arsitektur yang digunakan membutuhkan data ukuran input yang berbeda. Peneliti menggunakan arsitektur CNN MobileNetV2, sehingga fitur inputan yang dibutuhkan arsitektur disesuaikan 224x224 pixel. Kebutuhan perubahan dataset yang lainnya, seperti risizing, cropping, random flip, dan random rotation.

Setelah melakakukan transformasi dataset, kemudian proses hyperparameter pada dataset untuk dijadikan dataloader. Dataloader merupakan dataset yang akan dijadikan data untuk training maupun testing. Proses yang dilakukan yaitu dengan membagi menjadi beberapa bagian atau batch. Peneliti membagi dataset dengan ukuran tiap bagiannya atau batch size 64 dan 32. Pembagian tersebut dilakukan secara acak dengan membutuhkan 4 core untuk melakukan eksekusi. Penjelasan tersebut peneliti lampirkan pada gambar.



gambar 10. Minibatch

### H.3.4 Perancangan Astitektur Model



gambar 11. Custom MobileNetV2

Proses ini merupakan perancangan CNN yang akan digunakan. Peneliti menggunakan arsitektur MobileNetV2 untuk klasifikasi jenis penyakit daun pada tanaman jagung dengan basis pytorch. Peneliti melakukan modifikasi pada arsitektur MobileNetV2, karena output yang dihasilkan pada model arsitektur mobilenetv2 tersebut ditujukan untuk melakukan klasifikasi 1000 objek. Peneliti akan merubah klasifikasi dari 1000 kelas menjadi 4 kelas yang digunakan pada penelitian ini.

Proses setelah arsitektur terbentuk, selanjutnya menentukan hyperparameter atau parameter berpengaruh yang digunakan sebelum melakukan pelatihan model. Peneliti akan menggunakan hyperparameter menghitung *loss*, *optimizer*, *learning rate*, dan *early stopping*. Peneliti memanfaatkan fungsi *Callback* untuk mencari nilai gagal atau loss terendah dan menyimpan model terbaik. *Early stopping* yaitu nilai yang digunakan untuk menghentikan perulangan jika model yang dilatih bagus secara berturut turut. Peneliti akan menggunakan optimizer *adamw*, fungsi loss untuk menghitung loss kategorikal, learning rate 0.001 dengan *early stop* 5 dan *learning rate* 0.0001 dengan *early stopping* 10.

### H.3.5 Pengujian dan evaluasi

Proses dari tahapan ini adalah untuk mengetahui performa model yang telah dibuat. Metode yang digunakan adalah confusion matrix. Proses ini dilakukan untuk untuk mendapatkan hasil evaluasi model yang dibuat.

### H.3.6 Integrasi sistem

Tahapan ini bertujuan untuk mendeploy model yang telah dibuat. Kemudian melakukan integrasi system deteksi objek berbasis web. Peneliti membuat system web untuk melakukan model yang dibuat bisa digunakan dengan baik. Diharapkan dengan integrasi system ini, dapat menyelesaikan masalah yang mentaji tujuan peneltian.

### H.3.7 Pengujian system

Proses pada tahapan ini melakukan pengujian pada system yang telah dibuat. Peneliti menggunakan *blackbox testing* untuk pengujiannya. Diharapkan pengujian ini sistem yang dibuat dapat diuji dan digunakan dengan baik.

### H.4 Luaran yang diharapkan

Hasil yang diharapkan dalam penelitian ini ialah skripsi dan jurnal ilmiah yang dipublikasikan.

### H.5 Jadwal Penelitian

Table 2. Tabel Jadwal Penelitian

No.	Tahapan Penelitian	2022	2023				
		Des.	Jan.	Feb.	Mar.	Apr.	Mei
1	Pengumpulan dataset						
2	Preprocessing dataset						
3	Perancangan Model						
4	Pengujian dan evaluasi model						
5	Implementasi sistem						
6	Testing						

## I. DAFTAR PUSTAKA

- Buana Pura, W. S. S., Ferdinan, H., Kadir, Haryanto, S., & Suwarti. (2021). *ANALISIS PRODUKTIVITAS JAGUNG DAN KEDELAI DI INDONESIA 2020 (HASIL SURVEI UBINAN) BADAN PUSAT STATISTIK BPS-STATISTICS INDONESIA*.
- Ireri, D., Belal, E., Okinda, C., Makange, N., & Ji, C. (2019). A computer vision system for defect discrimination and grading in tomatoes using machine learning and image processing. *Artificial Intelligence in Agriculture*, 2, 28–37.  
<https://doi.org/10.1016/j.aiia.2019.06.001>
- Jan, S. R., Tauhid, S., Shah, U., Johar, Z. U., Shah, Y., & Khan, F. (2016). *An Innovative Approach to Investigate Various Software Testing Techniques and Strategies*. January.
- KC, K., Yin, Z., Wu, M., & Wu, Z. (2019). Depthwise separable convolution architectures for plant disease classification. *Computers and Electronics in Agriculture*, 165(August), 104948. <https://doi.org/10.1016/j.compag.2019.104948>

- Khan, S., Rahmani, H., Shah, S. A. A., & Bennamoun, M. (2018). A Guide to Convolutional Neural Networks for Computer Vision. *Synthesis Lectures on Computer Vision*, 8(1), 1–207. <https://doi.org/10.2200/s00822ed1v01y201712cov015>
- O'Shea, K., & Nash, R. (2015). *An Introduction to Convolutional Neural Networks*. 1–11. <http://arxiv.org/abs/1511.08458>
- Panigrahi, K. P., Das, H., Sahoo, A. K., & Moharana, S. C. (2020). Maize Leaf Disease Detection and Classification Using Machine Learning Algorithms. *Advances in Intelligent Systems and Computing*, 1119, 659–669. [https://doi.org/10.1007/978-981-15-2414-1\\_66](https://doi.org/10.1007/978-981-15-2414-1_66)
- Rahman, C. R., Arko, P. S., Ali, M. E., Iqbal Khan, M. A., Apon, S. H., Nowrin, F., & Wasif, A. (2020). Identification and recognition of rice diseases and pests using convolutional neural networks. *Biosystems Engineering*, 194, 112–120. <https://doi.org/10.1016/j.biosystemseng.2020.03.020>
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 4510–4520. <https://doi.org/10.1109/CVPR.2018.00474>
- Santos-Bustos, D. F., Nguyen, B. M., & Espitia, H. E. (2022). Towards automated eye cancer classification via VGG and ResNet networks using transfer learning. *Engineering Science and Technology, an International Journal*, xxxx, 101214. <https://doi.org/10.1016/j.jestch.2022.101214>
- Sarkar, D., Bali, R., & Sharma, T. (2018). Deep Learning for Computer Vision. In *Practical Machine Learning with Python* (pp. 499–520). Apress. [https://doi.org/10.1007/978-1-4842-3207-1\\_12](https://doi.org/10.1007/978-1-4842-3207-1_12)
- Sibiya, M., & Sumbwanyambe, M. (2019). A Computational Procedure for the Recognition and Classification of Maize Leaf Diseases Out of Healthy Leaves Using Convolutional Neural Networks. *AgriEngineering*, 1(1), 119–131. <https://doi.org/10.3390/agriengineering1010000>
- Singh, D., Jain, N., Jain, P., Kayal, P., Kumawat, S., & Batra, N. (2020). PlantDoc: A dataset for visual plant disease detection. *ACM International Conference Proceeding Series*,

November, 249–253. <https://doi.org/10.1145/3371158.3371196>

Sudjono, M. S. (2018). *Penyakit Jagung dan Pengendaliannya*.

<http://balitsereal.litbang.pertanian.go.id/wp-content/uploads/2018/08/11penyakit.pdf>